

INVESTISSEURS
DIRIGEANTS
EXPERTS
ASSOCIÉS


Sensibilisation à l'usage de l'IA en entreprise

Bootcamp IA agentique des 20-21 Juillet 2026

Mes coordonnées

- Charles Pourreau
- M. +33(0) 686 87 18 34
- charles.pourreau@idea-email.com
- charles.pourreau@entrepreneurs-incube.fr

Le 30
Novembre
2022

The image is a screenshot of the OpenAI website's homepage as it appeared in late 2022. The header features the OpenAI logo on the left, followed by navigation links for 'Research', 'Product', 'Safety', and 'Company'. On the right side of the header are links for 'Search', 'Log in', and a 'Sign up' button. The main content area has a dark green background. On the left, the text 'Introducing ChatGPT' is written in a large, light blue font. Below this, a paragraph describes the model: 'We've trained a model called ChatGPT which interacts in a conversational way. The dialogue format makes it possible for ChatGPT to answer followup questions, admit its mistakes, challenge incorrect premises, and reject inappropriate requests.' At the bottom of this text block are two buttons: 'Try ChatGPT' and 'Read about ChatGPT Plus'. To the right of the text is a large, abstract graphic consisting of many horizontal bars of varying lengths and colors, primarily in shades of blue and green, creating a sense of depth and movement.

OpenAI

Research Product Safety Company

Search Log in Sign up

Introducing ChatGPT


We've trained a model called ChatGPT which interacts in a conversational way. The dialogue format makes it possible for ChatGPT to answer followup questions, admit its mistakes, challenge incorrect premises, and reject inappropriate requests.

Try ChatGPT Read about ChatGPT Plus

Explosion du nombre d'utilisateurs


Source: OpenAI (sept 2025)

1M utilisateurs
en 5 jours



Explosion du nombre de requêtes par utilisateur


Source: OpenAI (sept 2025)



L'usage de l'IA en entreprise a immédiatement explosé

Source: Energy and AI –
International Energy Agency,
Avril 2025

Figure 1.5 ▶ Growth in the use of digital technologies in the workplace since the year of first commercial release, United States




IEA. CC BY 4.0.




There has been a rapid uptake of generative AI applications in the workplace, enabled by the widespread adoption of personal computers and the Internet in US workplaces

Pourquoi intégrer l'IA ? Pourquoi maintenant ?


Une évolution de la technique à l'origine de l'évolution des usages



Analogie à 2 paramètres



Une évolution de la technique à l'origine de l'évolution des usages



Tokenisation

Raconte-moi une histoire de Jojo le poulpe

Raconte-moi une histoire de Jojo le poulpe

Raconte-moi une histoire de Jojo le poulpe

1 mot = 1,4 token environ
1 token = 0,75 mot environ

1 page A4
= 450 mots environ
= 600 tokens environ

<https://platform.openai.com/tokenizer>

Raconte-moi une histoire de Jojo le poulpe


Clear Show example

Tokens	Characters
13	43

Raconte-moi une histoire de Jojo le poulpe

Text Token IDs

Tokenisation



1 token = 28x28 pixels ou
32x32 pixels environ

Image 1280x720 pixels
= 1100 tokens environ

https://stellaxon.com/ai/image-token-calculator

SX

STELLAXON

TOOLS

Finance

Startup

Converters

Generators

Developer

All Tools

Search

/

Select Vision Model

GPT-4o (OpenAI)

\$2.5/1M

GPT-4o mini (OpenAI)

\$0.15/1M

GPT-4 Turbo (OpenAI)

\$10/1M

Claude 3.5 Sonnet (Anthropic)

\$3/1M

Claude 3 Opus (Anthropic)

\$15/1M

Claude 3 Haiku (Anthropic)

\$0.25/1M

Gemini 2.0 Flash (Google)

\$0.1/1M

Gemini 1.5 Pro (Google)

\$1.25/1M

Most capable for complex analysis

Image Settings

Resolution Preset

HD (1280×720)

Width (px)

1280

Height (px)

720

Number of Images

1

Additional Text Tokens (prompt + response)

500

Include your prompt and expected response tokens

Token & Cost Estimate

Reset

Tokens per Image

1272

0.92 MP

Total Image Tokens

1272

1 image

Total Tokens

1772

+ 500 text tokens

Total Cost

\$0.026580

\$0.019080/image

 INVESTISS
DIRIGEANTS
EXPERTS
ASSOCIÉS

Sensibilisation IA
16
Jeu – Juillet 2026


Embedding



Embedding = 5% des paramètres du modèle

Notion de taille de 'vocabulaire'

50k tokens pour GPT3



Capture d'écran 3Blue1Brown

Attention (mécanisme de)

Raconte-moi une histoire de Jojo le poulpe




[0,33	[0,46
0,41	0,41
0,98	0,98
0,73	0,44
0,10	0,31
...	...
...	...
...	...
...	...
0,93	0,83
0,89	0,89
0,27]	0,27]



L'histoire de France au Moyen-Âge



[0,33	[0,76
0,41	0,41
0,98	0,84
0,73	0,66
0,10	0,10
...	...
...	...
...	...
...	...
0,93	0,93
0,89	0,17
0,27]	0,27]



Attention = 30% des paramètres du modèle



ChatGPT

Generative

Pre-trained

Transformer

[Generative] Une approche probabiliste ...

Raconte-moi une histoire de Jojo le poulpe

Il ...

Il était ...

Il était une ...

Il était une fois ...

Il était une fois Jojo ...

Il était une fois Jojo le poulpe, ...

Il était une fois Jojo le poulpe, un ...


Il était une fois Jojo le poulpe, un petit ...

Il était une fois Jojo le poulpe, un petit poulpe ...

[Generative] Une approche probabiliste ...



Step 1



Step 2



Step 3



Step 6




Step 9




Step 12


[Pre-Trained] ... nourrie d'un corpus de référence ...



[Transformer] ... avec une approche mécaniste




Parameters, Weights



Toute reproduction interdite

Anatomie d'un modèle IA (transformer)




Block transformer (MLP)

- MLP: multilayer perceptron
- MLP = 65% des paramètres du modèle
- Chaque couche de MLP est un pas sur le chemin entre l'Input et l'Output
- Le savoir du modèle
 - Base de connaissance
 - Capacité de réflexion
- GPT3 = 96 couches

Les différents types de modèles

- LLM (Large Language Model)
 - Modèles de langage pour le texte | Ex: GPT-4, Claude, Llama | 7B-1000B+ paramètres
- SLM (Small Language Model)
 - Versions compactes pour usage local | Ex: Phi-3, Gemma | <10B paramètres
- VLM (Vision-Language Model)
 - Multimodaux texte + images | Ex: GPT-4V, Claude 3.5 Sonnet, Gemini
- Modèles génératifs média
 - Images : DALL-E, Midjourney, Stable Diffusion
 - Audio/Musique : MusicGen, ElevenLabs
 - Vidéo : Sora, Runway, Pika
- Modèles spécialisés
 - OCR: GLM-OCR, Paddlepaddle
 - Code : Nemotron, CodeLlama, DeepSeek-Coder
 - Science : AlphaFold (protéines), ChemBERTa (chimie)
 - 3D : Shap-E, TripoSR
- RRM (Recurrent Reasoning Models)



Le cycle de vie d'un modèle IA





Les principaux paramétrages du modèle

- Température
- Top_k
- Taille de contexte
- Nombre de tokens générés
- Prefix-cache
- KV cache quantization

Une évolution de la technique à l'origine de l'évolution des usages




Début 2026 Openclaw fait évoluer les agents de codage vers des agents assistants puis des agents autonomes



Exemples d'usages


Pilotage financier TPE



Data processing

Chatbot métier

Copilote métier Qualiopi



Responsable Achats



Création d'un devis à partir d'un devis fournisseur



Création d'une commande fournisseur à partir d'un devis



Validation de la commande avec règles métiers

- Affectation de la commande à une affaire
- Plafond d'engagement par utilisateur par affaire
- ...



Edition du bon de commande en format .pdf
Liaison avec ERP



Extraction de données

- Gestion des engagements par projet
- Prévisionnel de trésorerie
- ...

Briques spécifiques d'IA open-source


- Outil de détection visuelle
- Outil de reconnaissance de caractère (OCR)
- Outil de transcription sonore : speech-to-text et text-to-speech
- Outil de création de vidéos
- Outil de classification
- Outil de traduction
- Outil de prévision météorologique



Briques d'IA (ML) envisageables


- Modèle de prédiction
- Modèle de classification
- Modèle solveur

5	3			7				
6			1	9	5			
	9	8					6	
8				6				3
4			8		3			1
7				2				6
	6					2	8	
			4	1	9			5
				8			7	9



La capacité à appréhender un contexte est déterminante


La capacité à appréhender un contexte est déterminante




Contexte (1)

- En phase d'inférence l'input pour chaque cycle de calcul s'appelle le contexte
- La taille de contexte est exprimée en tokens
- Pour de la génération de texte basique
 - Pour premier token généré → Contexte = Prompt utilisateur
 - Pour dernier token généré → Contexte = Prompt utilisateur + texte généré
- Pour de la génération d'image basique
 - Contexte = Prompt utilisateur + Image en construction
- 2048 tokens pour GPT3
- Désormais fréquemment 256k tokens voire 1M tokens

Contexte (2)



Contexte (3)



Contexte (4)


- Historique de conversation pour un chat
- Données multimodales
- Structure attendue de données de sorties
- Autres métadonnées injectées par le moteur d'inférence
- ...

Impact de la taille du contexte

Contexte x2 ➔

- Nb de calculs x4
- Mémoire(context) x2

“Context rot”



La promesse de production intellectuelle à coût marginal proche de zéro est vertigineuse

La promesse de production intellectuelle à coût marginal proche de zéro est vertigineuse

- Evolution forte et brusque des règles de compétitivité sur (probablement) tous les secteurs d'activité
 - Rareté de compétences clés dans les stratégies de différenciation
 - Traitement et création d'informations
- Optimisation de l'efficacité opérationnelle de l'entreprise
 - Frugalité des process supports
 - Optimisation permanente des process métiers
- Accélération de la vitesse d'horloge des marchés
 - Mises sur le marché
 - Organisations plates, modulaires, éphémères

La promesse faite par l'IA
ne doit pas se réaliser à
n'importe quel prix

Cette promesse ne doit pas se réaliser à n'importe quel prix

- Confidentialité / Conformité
- Souveraineté
- Coûts d'exploitation = production/consommation de tokens
- Production de tokens = Consommation électrique + Consommation en eau


L'absence d'encadrement des pratiques entraine le "Shadow IA"



Question : « *Lorsque vous utilisez l'IA dans le cadre de votre travail, accédez-vous aux outils d'IA avant tout via votre compte personnel ou via un compte d'entreprise ou professionnel fourni par votre employeur ?* » (une réponse par item)

Source : « *Workforce Survey on AI Adoption* », Ipsos bva pour Google, 2025
Base : Population active en emploi utilisant l'IA dans le cadre professionnel (France)

Chat GPT représente plus des trois quarts (76 %) du temps total d'utilisation des services d'IA en avril 2026



Source : Médiamétrie Netratings – Baromètre d'audience des services d'intelligence artificielle – Juin 2026

Strasbourg

Le FBI prévient la police de menaces contre des agents du renseignement, le Raid intervient

Ach.H. et Cel. L – 05 avr. 2026 à 18:21 | mis à jour le 06 avr. 2026 à 15:19 – Temps de lecture : 1 min

D'une recherche ChatGPT à l'intervention du Raid, le coup de com' d'OpenAI

Un Français a demandé à ChatGPT comment se procurer une arme pour attaquer un agent du renseignement, le Raid l'a interpellé dans la foulée, ce qui interroge sur la politique de confidentialité de la start-up américaine.

Tout commence à Strasbourg, un homme de 37 ans interroge son agent conversationnel habituel, ChatGPT, pour une demande bien particulière, il veut savoir comment se procurer "un Glock", un pistolet automatique pour "tuer un agent du renseignement de la CIA, du Mossad ou de la DGSI". Quelques heures plus tard, l'homme se retrouve interpellé par l'unité d'élite du RAID, placé en garde à vue avant de ressortir. Sa défense ? Il souhaitait simplement vérifier le système de sécurité de l'IA.

*Source: Dernières Nouvelles d'Alsace
repris par Radio France – Avril 2026*

Les limites de confidentialité de la donnée

- Bien entendu, ne jamais saisir de données confidentielles d'entreprise dans un compte IA personnel
- Utilisation des données par les services d'IA
 - Les forfaits gratuits supposent en général l'usage des données utilisateurs pour l'entraînement des modèles suivants
 - Les modèles payants permettent de désactiver cet usage ou l'excluent par défaut
 - Données concernées
 - Prompts et réponses
 - Historique de discussions
 - Fichiers et images transmis
 - Logs d'inférence
- Le Cloud Act permet aux autorités américaines d'exiger certaines données auprès de fournisseurs numériques soumis au droit US
 - Données stockées sur cloud non chiffrées (client-side encryption)
 - Données traitées ou conservées sur serveur d'inférence IA

Les limites de conformité (ex RGPD)

- Bien entendu,
 - ne jamais utiliser une donnée personnelle sur un compte IA personnel
 - ne jamais partager une donnée personnelle qui pourrait être utilisée comme donnée d'entraînement de modèles d'IA
- L'envoi de données personnelles sur une IA doit être encadrée pour garantir la conformité RGPD
- Sur un champ d'usage très commun
 - Sauf engagement contractuel explicite de “résidence d'inférence” en UE, une entreprise ne peut pas garantir que les prompts et données transmises à un fournisseur d'inférence US sont traités sur des serveurs de calcul situés dans l'UE.
 - Lorsqu'une donnée personnelle est transmise à un serveur d'inférence situé hors UE/EEE, l'entreprise doit encadrer ce transfert et, selon le pays et le fournisseur, mettre en place des garanties ou mesures complémentaires pour maintenir la conformité RGPD.

Les points de vigilance

- Logiciels SaaS avec briques d'IA
 - CRM : Hubspot, Salesforce, ...
 - Bases documentaires : Notion, Confluence, ...
 - Suites bureautiques: Gemini dans Google Workspace, Copilot dans Microsoft 365, ...
 - Outils métiers: RH, support client, gestion de projet, comptabilité, ...
 - ...
- Services de transcription
 - Robots de compte-rendus de réunion
 - Outils de transcription, prises de notes: Plaud, Pocket, ...
- Une brique IA intégrée dans un SaaS peut transmettre des données personnelles ou confidentielles à un sous-traitant d'inférence, parfois sans que l'utilisateur en ait conscience.

Les limites de souveraineté

ANTHROPIC

ResearchPolicyCommitments ▾Learn ▾NewsTry Claude ▾

Announcements

Statement on the US government directive to suspend access to Fable 5 and Mythos 5


12 juin 2026

The US government, citing national security authorities, has issued an export control directive to suspend all access to Fable 5 and Mythos 5 by any foreign national, whether inside or outside the United States, including foreign national Anthropic employees. The net effect of this order is that we must abruptly disable Fable 5 and Mythos 5 for all our customers to ensure compliance. **Access to all other Anthropic models will not be affected.**

We received the directive from the government today at 5:21pm (ET). The letter did not provide specific details of its national security concern. Our understanding is that the government believes it has become aware of a method of bypassing, or “jailbreaking” Fable 5. We reviewed a demonstration of this specific technique being used to identify a small number of previously known, minor vulnerabilities. These vulnerabilities all appear relatively simple, and we have found that other publicly-available models are able to discover them as well without requiring a bypass.


L'impact environnemental de l'IA sans limite

Figure 2.14 ▶ Global data centre electricity consumption by sensitivity case, 2020-2035



The outlook for data centre electricity demand is highly uncertain, driven by factors including efficiency improvements, AI uptake and potential energy sector bottlenecks

Figure 2.13 ▶ Increase in electricity demand by sector in the Base Case, 2024-2030



Data centres contribute more to global electricity demand growth than heavy industry or space and water heating

Source: Energy and AI – International Energy Agency, Avril 2025

L'IA Act ou règlement sur l'IA

[règlement (UE) 2024/1689 établissant des règles harmonisées sur l'intelligence artificielle]

L'IA Act

- La législation sur l'IA (AI Act), qui est entrée en vigueur le 1 août 2024, crée un marché unique et des règles harmonisées pour une IA digne de confiance dans l'UE. Elle vise à promouvoir l'innovation et l'adoption de l'IA, tout en s'attaquant aux risques potentiels pour la santé, la sécurité et les droits fondamentaux des personnes et en préservant la démocratie et l'état de droit.
- Mise en application progressive entre 2024 et 2027
- Une entreprise qui utilise l'IA à titre professionnel peut être qualifiée de déployeur au sens de l'IA Act. Elle doit notamment assurer un niveau suffisant de maîtrise de l'IA pour les personnes qui utilisent ces systèmes pour son compte. En pratique, cela conduit à former les équipes, encadrer les usages, identifier les cas sensibles et vérifier si certains outils relèvent d'obligations spécifiques, notamment en cas d'IA à haut risque ou d'obligations de transparence

IA Act: Définitions clés

- «système d'IA», un système automatisé qui est conçu pour fonctionner à différents niveaux d'autonomie et peut faire preuve d'une capacité d'adaptation après son déploiement, et qui, pour des objectifs explicites ou implicites, déduit, à partir des entrées qu'il reçoit, la manière de générer des sorties telles que des prédictions, du contenu, des recommandations ou des décisions qui peuvent influencer les environnements physiques ou virtuels;
- «déployeur», une personne physique ou morale, une autorité publique, une agence ou un autre organisme utilisant sous sa propre autorité un système d'IA sauf lorsque ce système est utilisé dans le cadre d'une activité personnelle à caractère non professionnel;
- «fournisseur», une personne physique ou morale, une autorité publique, une agence ou tout autre organisme qui développe ou fait développer un système d'IA ou un modèle d'IA à usage général et le met sur le marché ou met le système d'IA en service sous son propre nom ou sa propre marque, à titre onéreux ou gratuit;

1. La loi sur l'IA classe l'IA en fonction des risques qu'elle présente :

- Les risques inacceptables sont interdits (par exemple, les systèmes de notation sociale et l'IA manipulatrice).
- La majeure partie du texte porte sur les systèmes d'IA à haut risque, qui sont réglementés.
- Une section plus petite traite des systèmes d'IA à risque limité, soumis à des obligations de transparence plus légères : les développeurs et les déployeurs doivent s'assurer que les déployeurs finaux sont conscients qu'ils interagissent avec l'IA (chatbots et deepfakes).
- Le risque minimal n'est pas réglementé (y compris la majorité des applications d'IA actuellement disponibles sur le marché unique de l'UE, telles que les jeux vidéo et les filtres anti-spam activés par l'IA - au moins en 2021 ; cette situation est en train de changer avec l'IA générative).

<https://artificialintelligenceact.eu/fr/high-level-summary/>

2. La majorité des obligations incombent aux fournisseurs (développeurs) de systèmes d'IA à haut risque.

- Ceux qui ont l'intention de mettre sur le marché ou de mettre en service des systèmes d'IA à haut risque dans l'UE, qu'ils soient basés dans l'UE ou dans un pays tiers.
- Ainsi que les fournisseurs de pays tiers où les résultats du système d'IA à haut risque sont utilisés dans l'UE.

<https://artificialintelligenceact.eu/fr/high-level-summary/>

3. Les déployeurs sont des personnes physiques ou morales qui déploient un système d'IA à titre professionnel

- Les déployeurs sont des personnes physiques ou morales qui déploient un système d'IA à titre professionnel, et non des déployeurs finaux concernés.
- Les déployeurs (déployeurs) de systèmes d'IA à haut risque ont certaines obligations, mais moins que les fournisseurs (développeurs).
- Cela s'applique aux déployeurs situés dans l'UE et aux déployeurs de pays tiers lorsque les résultats du système d'IA sont utilisés dans l'UE.

<https://artificialintelligenceact.eu/fr/high-level-summary/>

4. IA à usage général (GPAI) :

- Tous les fournisseurs de modèles GPAI doivent fournir une documentation technique, des instructions d'utilisation, se conformer à la directive sur les droits d'auteur et publier un résumé du contenu utilisé pour la formation.
- Les fournisseurs de modèles GPAI sous licence libre et gratuite doivent uniquement respecter les droits d'auteur et publier le résumé des données de formation, à moins qu'ils ne présentent un risque systémique.
- Tous les fournisseurs de modèles GPAI qui présentent un risque systémique - qu'ils soient ouverts ou fermés - doivent également procéder à des évaluations de modèles, à des tests contradictoires, suivre et signaler les incidents graves et assurer la protection de la cybersécurité.

<https://artificialintelligenceact.eu/fr/high-level-summary/>

Sources et outils d'auto-contrôle

- <https://artificialintelligenceact.eu>
- <https://artificialintelligenceact.eu/fr/evaluation/verificateur-de-conformite-a-l-acte-de-l-ai-de-l-ue/>
- <https://ai-act-service-desk.ec.europa.eu/fr/controle-de-conformite-au-reglement-de-lue-sur-lia>

Peut-on envisager une IA souveraine et raisonnée à l'échelle d'une PME ?


Pourquoi souveraine et raisonnée ?

- Confidentialité / Conformité / Souveraineté
- Coûts d'exploitation = production de tokens
- 1 usage = 1 solution spécifique
- Technologie avec une maturité permettant un déploiement en entreprise
 - GPUs
 - Moteurs d'inférence
 - Modèles LLM et modèles experts
 - Usages : data processing / chatbot / agent

Le 20 Janvier 2025

DeepSeek-R1 Release

- ⚡ Performance on par with OpenAI-o1
- 📖 Fully open-source model & technical report
- 🏆 Code and models are released under the MIT License: Distill & commercialize freely!
- 🌐 Website & API are live now! Try DeepThink at chat.deepseek.com today!



IA Cloud vs IA Locale

IA Cloud

- Donnée publique
- RGPD par anonymisation
- Modèles 'frontier' propriétaires
- Modèles open-source
- Vitesse de déploiement
- Coût d'usage : token = coût variable

IA Locale

- Donnée confidentielle
- RGPD native
- Optimisation et maîtrise des process IA
 - Gestion des portefeuilles de modèles
 - Paramétrage des modèles en inférence
- Stabilité des process IA
 - Maîtrise du versioning
 - Stabilité du comportement des modèles
- Coût d'infrastructure + "ML Ops"
- Coût marginal d'inférence quasi-nul



Les leviers pour diminuer la puissance nécessaire

- Gestion d'un portefeuille de modèles
 - Modèles 'general purpose' vs Modèles experts 'task specific'
 - Modèles denses vs Modèle MoE (Mixture of Experts)
- Utilisation optimisée
 - Context engineering voire fine-tuning
 - Puissance bridée des GPUs
 - Parallélisation
 - Speculative decoding
- Techniques de compression
 - Distillation : Petit modèle créé à partir d'un grand modèle
 - Quantization : FP8/INT8/INT4 au lieu de BF16 (mémoire /2, /4 ou 8)
 - Pruning : Suppression de paramètres inutiles
- Optimisations algorithmiques
 - KV Cache : Réutilisation des calculs précédents
 - FlashAttention : Calcul d'attention optimisé (mémoire /3)


Les briques d'une infrastructure souveraine pour une PME

- Serveur de calcul
 - VRAM entre 48GB et 480GB pour supporter les modèles d'IA
 - Vitesse de calcul en fonction des usages
 - Entre 8k€ et 80k€
- Modèles IA open-source
 - Gratuits
 - Coûts ponctuels liés pour mise en place et récurrents pour les mises à jour
- Eventuellement modèles IA propriétaires
 - Coûts liés à la préparation de la donnée et à création des modèles
 - Capacité de calcul en fonction du type et de la taille du modèle
- Briques logicielles open-source
 - Gratuits
 - Coûts ponctuels liés pour mise en place et récurrents pour les mises à jour


Chatbot ? Agent assistant ? Agent autonome ?




Un chatbot utilise le LLM pour répondre aux questions




Le chatbot peut intégrer du contexte entreprise




L'agent assistant aide ou agit pour le compte de l'utilisateur




L'agent assistant peut combiner les deux contextes



L'agent autonome décide et agit pour son propre compte




L'agent autonome devient un membre de l'organisation




Le modèle du logiciel est attaqué

Le schéma du logiciel métier 'Software as a Service'




'ChatBot is the new UI'



* ChatBot = Agent conversationnel

Toute reproduction interdite


'Agent as a service'



* ChatBot = Agent conversationnel

Toute reproduction interdite

'Software as an Agent'



L'Intelligence artificielle n'est pas une solution miracle

Savoir quand utiliser l'IA et savoir quand ne pas utiliser l'IA


Quand utiliser l'IA ?

- L'IA est pertinente lorsque la tâche implique :
 - du langage naturel ;
 - des documents non structurés ;
 - de l'ambiguïté ;
 - une classification nécessitant du contexte ;
 - une synthèse ou une reformulation ;
 - la sélection d'une action parmi plusieurs possibilités ;
 - une adaptation à des situations différentes.
- Exemples en usage agentique:
 - comprendre une demande formulée librement ;
 - extraire les informations d'une facture ;
 - déterminer le type d'une dépense ;
 - analyser un contrat ;
 - choisir quel outil ou quelle skill appeler ;
 - rédiger un email à partir d'un contexte ;
 - détecter qu'une information semble incohérente ou ambiguë.

Quand utiliser un outil déterministe (script, tâche planifiée, automatisatisation) ?

- Le script est préférable lorsque :
 - les règles sont connues et stables ;
 - le résultat doit être reproductible ;
 - une erreur serait coûteuse ;
 - il faut manipuler précisément des fichiers ou des données ;
 - il faut effectuer un calcul ;
 - il faut contrôler un format ;
 - il faut appeler une API avec des paramètres précis.
- Exemples :
 - vérifier que $HT + TVA = TTC$;
 - calculer une échéance ;
 - renommer et déplacer un fichier ;
 - effectuer une requête SQL ;
 - générer une facture PDF ;
 - envoyer un document vers le bon répertoire ;
 - vérifier qu'un champ respecte une expression régulière.

IA ou pas IA, quel IA ?



Cas 1 — Renommer des fichiers

- Chaque soir, l'entreprise doit renommer les fichiers déposés dans un dossier selon la règle :
- AAAA-MM-JJ_NomClient_NumeroDocument.pdf
- Toutes les informations nécessaires figurent déjà dans un fichier CSV structuré.
- IA, script, les deux, ou humain ?

Cas 2 — Trier des demandes clients

- Une boîte email reçoit des demandes formulées librement :
 - demande de devis ;
 - réclamation ;
 - question technique ;
 - demande de résiliation ;
 - message sans rapport avec l'entreprise.
- Il faut comprendre la demande et l'affecter au bon service.
- IA, script, les deux, ou humain ?

Cas 3 — Traiter des factures fournisseurs

- L'entreprise reçoit des factures PDF, parfois scannées. Il faut :
 - identifier le fournisseur ;
 - extraire la date et le numéro de facture ;
 - extraire les montants HT, TVA et TTC ;
 - vérifier que $HT + TVA = TTC$;
 - créer un fichier JSON ;
 - déplacer la facture dans le bon dossier ;
 - isoler les factures ambiguës.
- IA, script, les deux, ou humain ?

Cas 4 — Calculer des pénalités de retard

- À partir d'une base contenant :
 - le montant de la facture ;
 - la date d'échéance ;
 - la date de paiement ;
 - le taux de pénalité applicable ;
 - il faut calculer automatiquement les pénalités de retard.
- Les données sont structurées et la formule est connue.
- IA, script, les deux, ou humain ?

Cas 5 — Répondre à une réclamation client

- Un client indique dans un email qu'un produit est arrivé endommagé.
- Le système doit :
 - comprendre la réclamation ;
 - retrouver la commande dans l'ERP ;
 - vérifier la date d'achat et les conditions de garantie ;
 - proposer une réponse ;
 - déclencher un remboursement éventuel.
- Tout remboursement supérieur à **500 €** doit être approuvé par un responsable.
- IA, script, les deux, ou humain ?

Cas 6 — Analyser un contrat

- Une entreprise souhaite analyser un contrat commercial afin de repérer :
 - les clauses de renouvellement tacite ;
 - les limitations de responsabilité ;
 - les pénalités ;
 - les obligations inhabituelles ;
 - les clauses potentiellement défavorables.
- IA, script, les deux, ou humain ?

Cas 7 — Préparer un fichier de virements

- Chaque mois, l'entreprise génère un fichier de virements fournisseurs à partir des factures validées.
- Le système doit :
 - sélectionner les factures arrivées à échéance ;
 - contrôler les coordonnées bancaires ;
 - calculer le total ;
 - générer le fichier bancaire ;
 - empêcher l'envoi en cas d'incohérence.
- IA, script, les deux, ou humain ?

L'IA pour les startups permet d'accélérer la mise sur le marché

L'IA pour les startups permet d'accélérer la mise sur le marché

- Collecte d'informations
 - Etude de marché et veille concurrentielle
 - Veille réglementaire / Veille technologique
- Support équipe des fondateurs
 - Agent gestion de projet
 - Bot Running lean
- Création d'informations
 - Copywriting, stratégie de contenu
 - Décryptage sur aspects contractuels
 - Production de livrables
- Démonstrateurs
 - Landing page
 - Visuels
 - Logiciels / Apps en v0

Les startups peuvent intégrer l'IA dans leur modèle dès le jour 0

Votre brique numérique doit être utilisable par l'IA


- MCP
- SDK / ADK, CLI
- Web MCP

Vous devez intégrer l'IA comme une brique stratégique de votre organisation


- IA au service d'une vision stratégique et d'une ambition de différenciation
 - Pourquoi ?
 - Comment ?
 - Barrières ?
- Data centric ET Knowledge centric
 - Valorisation de la donnée
 - Sécurisation et déploiement de la connaissance / du savoir-faire de l'entreprise
- Organisation optimisée
 - Coût marginal proche de zéro
 - Optimization loop
 - Agilité et vitesse
- Critère d'investissement et de valorisation

Architecture agentique


Le schéma général Agent assistant



Le schéma général Agent autonome



Installation recommandée



Infrastructure IA

Une puissance de calcul nécessaire colossale

- Un contexte de X tokens
- Un modèle de Y Milliard de paramètres (en BF16)
- **FLOPs** (Floating Point Operations) : nombre d'opérations arithmétiques en virgule flottante (additions, multiplications) effectuées par un calcul.
 - FLOPs $\sim 2.X.Y.10^9$ par token généré
- Mémoire nécessaire = Poids du modèle + Mémoire du contexte
 - Mémoire nécessaire (GB) = $2.Y + 0,005.X$
- « Raconte-moi une histoire de Jojo le poulpe » avec GPT3 → 1000 tokens en sortie
 - → 355GB de mémoire
 - → FLOPs = 178.10^{15} FLOPs ou 178 PetaFLOPs
 - Un ordinateur de bureau performant (~ 10 TFLOPS) : ~ 5 heures de calcul → 1,25 kW.h
 - Une carte graphique haut de gamme (~ 100 TFLOPS) : ~ 30 minutes → 175 W.h
 - Une config IA optimisée : 10 secondes → 2 W.h

Infrastructure IA

Brique matérielle d'inférence

Brique matérielle

- Mémoire pour le modèle et le contexte
 - ➔ VRAM pour modèle et KV cache (contexte) avec GPU dédié
 - ➔ SoC à mémoire unifiée
- Besoin mémoire (exemple pour Qwen3.6-27B)
 - Chargement modèle :
 - 27b BF16 ➔ 54 GB
 - 27b FP8 ➔ 27 GB
 - 27b 4bit ➔ 14 GB
 - 27b NVFP4 => 20GB
 - KV cache par requête (taille de contexte)
 - Contexte 128k tokens ➔ 4GB pour cache en FP16
 - Contexte 128k tokens ➔ 2GB pour cache en FP8
 - Nb de requêtes concurrentes
 - Nb de requêtes x KV cache par requête

Brique matérielle

- La capacité d'inférence (token/s)
 - Capacité de calcul Tflops (prefill) + bande passante mémoire (génération)
 - ➔ GPU dédié sur serveur classique
 - ➔ Puce CPU-GPU sur architecture ARM
- Vitesse d'inférence:
 - Prompt throughput: pas dimensionnant en usage agentique
 - Generation: token/s $\sim$ bande passante $\div$ taille du modèle en mémoire
- Le GPU (constructeur et génération) utilisé impacte la compatibilité
 - Des bibliothèques de calcul et moteurs d'inférence utilisés
 - Des modèles quantisés

Brique matérielle

- L'orchestration (traitement des requêtes et les scripts)
 - ➔ CPU: dimensionnement pas réellement critique
- La préparation du modèle et le fonctionnement des autres services
 - ➔ RAM sur serveur classique (taille RAM $\sim 0,7 \times$ taille VRAM totale)
 - ➔ RAM unifiée sur architecture ARM
- Stockage
 - Espace disque $\gg$ Taille du modèle + stack logicielle d'inférence + OS
 - SSD NVMe pour chargement rapide du modèle

Infrastructure IA

Brique logicielle d'inférence

Moteurs d'inférence

- vLLM
- Llama.cpp
- SGLang
- MLX-LM

vLLM

- Moteur d'inférence conçu pour servir des modèles avec un débit élevé et plusieurs requêtes simultanées. Il optimise l'utilisation du KV cache, le regroupement dynamique des requêtes, les longs contextes et l'exécution multi-GPU.
- Il expose une API compatible OpenAI et prend en charge de nombreuses quantifications, le multimodal, le tool calling et les sorties structurées.
- À privilégier pour :
 - un serveur d'inférence NVIDIA ou AMD
 - plusieurs utilisateurs ou agents simultanés
 - des modèles FP8, FP4, GPTQ, AWQ
 - une infrastructure de production centralisée
- Positionnement : performance et concurrence sur serveur GPU.

Llama.cpp

- Implémentation principalement en C/C++ visant à exécuter des modèles avec peu de dépendances sur une grande variété de matériels : CPU x86, Apple Silicon, GPU NVIDIA ou AMD, Vulkan, etc.
- Son format de référence est GGUF et il propose de nombreuses quantifications de faible précision ainsi qu'un fonctionnement hybride CPU-GPU lorsque le modèle ne tient pas entièrement en VRAM.
- llama-server fournit aussi une API compatible OpenAI.
- À privilégier pour :
 - un ordinateur portable ou un poste de travail ;
 - les Mac à mémoire unifiée ;
 - une exécution CPU ou CPU-GPU ;
 - les modèles fortement quantifiés ;
 - une installation locale simple.
- Positionnement : portabilité, sobriété et diversité matérielle.

SGLang


- Framework de serving pour modèles de langage et modèles multimodaux, destiné aussi bien à un seul GPU qu'aux grands clusters. Il propose notamment le continuous batching, la paged attention, les sorties structurées, plusieurs formes de parallélisme et RadixAttention, qui réutilise efficacement les préfixes communs entre requêtes.
- Il expose des API compatibles OpenAI.
- À privilégier pour :
 - les serveurs GPU à haut débit
 - les workloads comportant beaucoup de préfixes partagés
 - les modèles récents ou les architectures MoE
 - les déploiements distribués avancés
- Positionnement : performance avancée, cache de préfixes et déploiements à grande échelle.
-

MLX-LM

- Bibliothèque développée dans l'écosystème Apple MLX pour exécuter, quantifier et entraîner légèrement des modèles de langage sur les Mac équipés de puces Apple Silicon.
- Elle exploite directement le CPU, le GPU et surtout la mémoire unifiée, sans devoir transférer les données entre une RAM système et une VRAM séparée.
- À privilégier pour :
 - un Mac mini, Mac Studio ou MacBook Apple Silicon
 - exploiter une grande quantité de mémoire unifiée
 - exécuter localement des modèles quantifiés
 - tester, convertir ou adapter des modèles MLX
 - construire un poste ou un serveur d'inférence entièrement basé sur du matériel Apple
- Positionnement : moteur d'inférence et de fine-tuning spécifiquement optimisé pour les Mac Apple Silicon.

Mon retour d'expérience

1




2

Intensité de l'évolution

- Solutions techniques
- Cas d'usages possibles

3

Utiliser / Intégrer l'IA oblige et permet une optimisation permanente



Glossaire

- **Intelligence artificielle**: ensemble des techniques permettant à des systèmes informatiques de simuler des capacités humaines telles que l'apprentissage, le raisonnement, la perception ou la prise de décision.*
- **Machine learning**: branche de l'intelligence artificielle qui permet à une machine d'apprendre automatiquement à partir de données et d'améliorer ses performances sur une tâche donnée sans être explicitement programmée.
- **Deep learning**: sous-branche du machine learning qui utilise des réseaux de neurones artificiels profonds pour apprendre automatiquement des représentations complexes à partir de grandes quantités de données.

Glossaire

- (Pre)training: phase durant laquelle un modèle est entraîné sur de très grands volumes de données afin d'apprendre les structures générales du langage ou du domaine avant toute adaptation à une tâche spécifique.
- Fine-tuning: technique qui consiste à adapter un modèle déjà entraîné en le réentraînant sur un jeu de données spécifique afin d'améliorer ses performances sur une tâche précise.
- Inférence: phase durant laquelle un modèle entraîné utilise de nouvelles données pour produire une prédiction, une classification ou une décision.